

Reconhecimento de Valores de Cédulas do Real em Tempo Real

Classificação por rede convolucional compacta, com anúncio por voz.

Kayky de Brito dos Santos
RA: 11202320900
Universidade Federal do ABC

André Marques da Silva
RA: 11202021067
Universidade Federal do ABC

Rafael de Souza Coelho
RA: 11202232212
Universidade Federal do ABC

Resumo—Este trabalho apresenta um sistema de visão computacional em tempo real que reconhece a denominação de cédulas do Real e a anuncia em voz alta, projetado para comerciantes com baixa visão. O sistema opera sobre uma maquete de bancada com fundo preto fosco e câmera fixa: cada quadro passa por uma localização clássica da cédula (limiarização de Otsu, abertura morfológica e maior contorno), o recorte resultante é classificado por uma rede neural convolucional compacta de 155.911 parâmetros treinada do zero sobre um conjunto de dados próprio de 1.393 imagens, e a denominação é anunciada por síntese de voz quando a confiança supera 80%. O classificador atinge 94,6% de acurácia e F1 macro de 0,944 sobre 278 imagens de validação, sem nenhuma confusão entre as notas de 50 e 100 reais, que é o par crítico apontado na entrevista que originou o projeto. Em testes com 8 voluntários externos e 42 tarefas, o sistema acertou 83,3% das tarefas com latência percebida de 2,81 s (desvio padrão 0,16 s) e pontuação SUS de 96,6. O resultado mais relevante é qualitativo: nenhuma das 7 falhas foi um valor errado anunciado, todas foram omissões, o que valida a decisão de projeto de preferir o silêncio ao palpite.

Index Terms—Visão computacional, redes neurais convolucionais, limiarização de Otsu, acessibilidade, reconhecimento de cédulas.

I. INTRODUÇÃO

Identificar corretamente o valor de uma cédula é uma operação trivial para quem enxerga bem e um risco financeiro recorrente para quem não enxerga. Em um caixa de comércio, o erro não é apenas um incômodo: ele se converte em prejuízo silencioso, repetido a cada transação mal conferida.

A. Origem do problema

O tema partiu de uma fase de empatia conduzida por meio de entrevistas. Duas delas definiram o projeto. A primeira, com uma comerciante de 61 anos com catarata inicial, revelou que a confusão mais frequente ocorre entre as notas de 50 e 100 reais, que o erro se agrava com luz fraca ou cédula amassada, e que já houve recebimento de notas trocadas de má fé. Como a entrevistada não enxerga o suficiente para enquadrar a nota em uma câmera, a interação precisa ser de “só encostar”. A segunda, com um auxiliar de caixa de 19 anos que hoje supre manualmente essa limitação conferindo o dinheiro, apontou como essenciais a simplicidade, a confiabilidade e o funcionamento com cédulas desgastadas, que são justamente as que mais circulam.

Desses relatos saíram os três requisitos que estruturam todo o restante do trabalho: tolerância a apresentação mal alinhada, robustez a cédulas em condição real de circulação e saída acessível por áudio.

B. Objetivo e escopo

O objetivo é construir um protótipo funcional que, a partir de uma câmera fixa sobre a área do caixa, classifique a denominação de uma cédula apresentada e anuncie o valor em voz alta, com erro conservador, isto é, respondendo com silêncio em vez de um valor errado. O escopo cobre as sete denominações em circulação; o protótipo entregue cobre seis (2, 5, 10, 20, 50 e 100 reais), com a nota de 200 reais fora do conjunto de dados por indisponibilidade de exemplar.

A hierarquia de erros é parte explícita da especificação, e não uma consequência do que a rede conseguiu aprender: confundir a nota de 50 com a de 100 reais é muito mais grave do que não reconhecer uma nota, porque o primeiro caso vira prejuízo e o segundo apenas pede uma nova aproximação da cédula.

C. Trabalhos relacionados e originalidade

Aplicativos de celular como Cash Reader e Seeing AI, e serviços de assistência humana como o Be My Eyes, resolvem um problema parecido, mas exigem segurar e mirar o aparelho, ou dependem de conexão de rede e de um voluntário remoto. Marcações táteis nas próprias cédulas falham com notas amassadas ou desgastadas. A proposta aqui apresentada se diferencia por ser fixa no ponto de venda, operada por aproximação, sem necessidade de mirar, e com retorno sonoro imediato, desenhada para a rotina descrita nas entrevistas.

II. METODOLOGIA

A. Arquitetura do sistema

O sistema tem uma fase *offline* (captura do conjunto de dados e treino da rede) e um laço em tempo real executado durante o uso. A fase *offline* produz um *checkpoint* com pesos, nomes das classes e tamanho de entrada, consumido pela etapa de classificação do laço. O laço em tempo real percorre as sete etapas da Tabela I a cada quadro.

A implementação está em quatro módulos Python com responsabilidade única, resumidos na Tabela II.

Tabela I
ETAPAS DO LAÇO EM TEMPO REAL, POR QUADRO

Etapa	Operação
1	Captura do quadro da câmera
2	Localização da cédula: Otsu, morfologia e maior contorno
3	Recorte da região de interesse
4	Classificação do recorte pela CNN
5	Corte por confiança (limiar 0,8)
6	Debounce da fala (7 s para a mesma nota)
7	Anúncio em áudio, com caixa e rótulo na tela

Tabela II
MÓDULOS DA IMPLEMENTAÇÃO

Arquivo	Responsabilidade
<code>capturar.py</code>	Captura interativa de imagens para o conjunto de dados
<code>localizacao.py</code>	Localização da cédula por visão clássica, compartilhada por treino e detecção
<code>treinar.py</code>	Treino da CNN e escrita do <i>checkpoint</i>
<code>detectar.py</code>	Detecção ao vivo, corte por confiança, síntese de voz e retorno visual

A decisão de projeto mais importante da arquitetura é que treino e detecção enxergam a mesma coisa: o mesmo módulo `localizacao.py` recorta a nota nas imagens de treino e no fluxo ao vivo. Isso elimina a diferença de distribuição entre os dois momentos, que é uma fonte clássica de degradação em produção.

B. Maquete e conjunto de dados primários

A maquete, mostrada em operação na Fig. 1, reproduz o balcão em escala de bancada: superfície com forro preto fosco e câmera fixa olhando para baixo, sustentada por um suporte de *headphone* com um braço horizontal de palitos de sorvete e contrapeso.




Figura 1. Maquete em uso: bancada preta fosca, câmera fixa no suporte improvisado, cédula posicionada na área central e o notebook ao lado executando a detecção ao vivo.

A captura usa uma *webcam* USB em resolução nativa, selecionada por nome no macOS, porque a ordem dos índices do AVFoundation muda conforme os dispositivos conectados. Todo o processamento roda em um notebook com Apple Silicon, com o treino usando a GPU integrada via MPS e retorno automático para CUDA ou CPU. Nada no pipeline depende do sistema operacional: os três pontos de contato com a plataforma (seleção de câmera, dispositivo de treino e síntese de voz) são isolados e têm caminho equivalente no Linux.

O conjunto de dados foi capturado inteiramente na maquete, cobrindo frente e verso, rotações e posições variadas dentro da área útil. A captura é feita por uma ferramenta interativa própria (Fig. 2), que mostra a classe ativa, o contador de imagens salvas e uma guia visual de enquadramento, permitindo trocar de denominação por tecla numérica e desfazer o último salvamento sem sair da sessão. A composição final está na Tabela III.




Figura 2. Ferramenta de captura durante uma sessão: classe ativa e contador no topo, guia verde de enquadramento e legenda das teclas de classe no rodapé.

Tabela III
COMPOSIÇÃO DO CONJUNTO DE DADOS

Classe	Imagens
vazio (bancada sem nota)	207
nota_2	200
nota_5	195
nota_10	200
nota_20	130
nota_50	271
nota_100	190
Total	1.393

A distribuição é moderadamente desbalanceada, com razão 2,1 entre a maior e a menor classe, e o treino não aplica reponderação nem amostragem balanceada. A classe `nota_200` está prevista no software, mas não foi capturada.

C. Localização da cédula por visão clássica

A separação entre nota e fundo usa limiarização de Otsu sobre a imagem em tons de cinza, precedida de suavização

Gaussiana 5×5 . Otsu escolhe o limiar T que maximiza a variância entre classes,

$$T^* = \arg \max_T \sigma_b^2(T) = \omega_0(T) \omega_1(T) [\mu_0(T) - \mu_1(T)]^2 \quad (1)$$

onde ω_0 e ω_1 são as probabilidades acumuladas das duas classes de intensidade e μ_0 e μ_1 suas médias. O método é adequado exatamente porque a maquete produz um histograma bimodal: bancada preta fosca de um lado, cédula clara do outro. Foi essa propriedade da maquete que permitiu trocar o detector de bordas de Canny, previsto na modelagem funcional, por um método mais simples e mais estável nesse cenário.

Em seguida, uma abertura morfológica com elemento estruturante elíptico 7×7 ,

$$A \circ B = (A \ominus B) \oplus B \quad (2)$$

remove pontos claros isolados, como reflexos e sujeira, sem encolher a região da nota. Dos contornos externos obtidos, o de maior área é tomado como a cédula, e é descartado se cobrir menos de 2% do quadro. A partir dele o módulo entrega duas saídas: a *bounding box* com folga de 5%, usada por treino e inferência, e os quatro pontos do retângulo rotacionado de área mínima, usados apenas para desenhar. Quando não há contorno aprovado, o sistema responde “vazio” sem chamar a rede, o que economiza inferência e reduz o falso positivo.

D. Classificação por rede convolucional

A rede é uma CNN compacta treinada do zero, sem *transfer learning*, em três blocos convolucionais seguidos de um classificador, conforme a Tabela IV.

Tabela IV
ARQUITETURA DA REDE, COM ENTRADA 192×192

Estágio	Composição	Saída
Bloco 1	Conv 3×3 ($3 \rightarrow 16$), Batch-Norm, ReLU, MaxPool 2×2	16×96^2
Bloco 2	Conv 3×3 ($16 \rightarrow 32$), Batch-Norm, ReLU, MaxPool 2×2	32×48^2
Bloco 3	Conv 3×3 ($32 \rightarrow 64$), Batch-Norm, ReLU, MaxPool 2×2	64×24^2
Pooling	AdaptiveAvgPool 4×4	64×4^2
Classificador	Flatten, Linear ($1024 \rightarrow 128$), ReLU, Dropout 0,4, Linear ($128 \rightarrow 7$)	7 logits

O modelo tem 155.911 parâmetros treináveis, sendo 23.808 nas convoluções e 132.103 no classificador. É um modelo deliberadamente pequeno: o problema tem sete classes visualmente muito distintas em condições de iluminação e fundo controladas, e a capacidade extra de uma rede grande seria gasta em decorar o conjunto de dados. A camada de *pooling* adaptativo fixa a dimensão de entrada do classificador independentemente do tamanho da imagem, o que permite treinar com entradas de 160 ou 192 pixels sem tocar na arquitetura.

A saída é convertida em distribuição de probabilidade por *softmax*,

$$p_c = \frac{e^{z_c}}{\sum_{k=1}^7 e^{z_k}} \quad (3)$$

e o treino minimiza a entropia cruzada $\mathcal{L} = -\log p_y$ com Adam (lr = 10^{-3}), *batch* 32, por 25 épocas. O *split* de validação é de 20%, reprodutível por semente fixa, aplicado por índices sobre duas visões do mesmo diretório, uma com aumento de dados e outra sem, o que garante que a validação nunca veja imagens aumentadas. O *checkpoint* salvo é o da melhor acurácia de validação e guarda pesos, nomes das classes e tamanho de entrada, de modo que o script de detecção reconstrói tudo sozinho.

O aumento de dados, aplicado apenas no treino, foi escolhido a partir das condições reais levantadas nas entrevistas, como mostra a Tabela V.

Tabela V
AUMENTO DE DADOS E A CONDIÇÃO REAL QUE CADA TRANSFORMAÇÃO SIMULA

Transformação	O que simula
RandomResizedCrop (escala 0,7 a 1,0)	Varição de distância e enquadramento parcial
RandomRotation (20°)	Nota apoiada torta, sem alinhamento
RandomHorizontalFlip e RandomVerticalFlip	Frente e verso, nota de cabeça para baixo
ColorJitter (brilho 0,5 a 1,0, contraste 0,4, saturação 0,2)	Varição de exposição e balanço de branco entre sessões

O parâmetro de brilho é intencionalmente assimétrico, apenas escurecendo: as capturas já saíram claras demais da *webcam* em modo automático, e clarear ainda mais estouraria as regiões brancas da cédula. Esse ajuste é a compensação de software para o fato de que o AVFoundation no macOS frequentemente ignora o travamento de exposição e balanço de branco pedido via OpenCV.

E. Decisão e anúncio

A classificação vira anúncio em três filtros encadeados. Primeiro, a classe prevista precisa ser uma cédula, pois a classe *vazio* nunca gera fala. Segundo, aplica-se o corte por confiança $p_{\max} \geq 0,8$, e predições abaixo do limiar são silenciadas. Terceiro, um *debounce* temporal impede que a mesma denominação seja repetida antes de 7 segundos, enquanto uma denominação diferente é anunciada imediatamente.

O terceiro filtro é a forma que a estabilização entre quadros prevista na modelagem funcional acabou tomando na implementação. A modelagem previa exigir N quadros consecutivos com a mesma predição; o *debounce* por tempo resolve o problema prático que motivava aquele bloco, que era a repetição do anúncio a cada quadro do laço, com estado mais simples, mas não filtra um quadro isolado espúrio da mesma forma que uma votação por maioria filtraria. É uma divergência consciente, registrada aqui como tal.

A fala usa o comando *say* no macOS e o *espeak* como alternativa, invocada de forma não bloqueante para não travar o laço de detecção. Em paralelo, a tela mostra a caixa rotacionada e o rótulo com denominação e confiança (Fig. 3), apoio para quem enxerga parcialmente ou para o auxiliar de caixa. A caixa acompanha a rotação da cédula porque é obtida

do retângulo de área mínima do contorno, e não da *bounding box* alinhada aos eixos usada para o recorte.




Figura 3. Saída da detecção ao vivo com uma cédula apoiada torta sobre a bancada: caixa rotacionada em verde acompanhando a inclinação da nota e rótulo com a denominação e a confiança.

F. Protocolo experimental

A avaliação tem duas frentes. A primeira mede o classificador isoladamente, sobre o *split* de validação de 20% (278 imagens), com o mesmo pré-processamento da inferência e decisão por *argmax*, isto é, sem o corte por confiança que o sistema ao vivo aplica.

A segunda mede o sistema completo com usuários. O roteiro definiu 11 tarefas cobrindo bancada vazia, as seis denominações, verso, rotação, nota amassada, apresentação desleixada, troca de nota, objeto que não é cédula, soma de um pagamento simulado e uso livre. As condições foram: sistema já configurado e rodando pela equipe, condutor que não corrige nem ajuda, um integrante registrando a ficha, sessão gravada em vídeo enquadrando bancada e tela e não o rosto, com duração alvo de 10 a 15 minutos. A sessão ocorreu em 10 de agosto de 2026, com 8 voluntários externos à equipe. Para cada tarefa foram anotados o acerto e o tempo até a resposta falada, e ao final cada voluntário preencheu uma ficha de opinião em papel contendo o *System Usability Scale* (SUS) [3], uma questão adicional sobre interatividade e seis questões abertas.

III. RESULTADOS

A. Desempenho do classificador

A matriz de confusão sobre as 278 imagens de validação está na Fig. 4, e as métricas por classe na Fig. 5 e na Tabela VI.

Tabela VI
MÉTRICAS POR CLASSE NO CONJUNTO DE VALIDAÇÃO

Classe	Precisão	Revocação	F1	n
nota_2	0,953	1,000	0,976	41
nota_5	1,000	0,846	0,917	39
nota_10	0,850	0,971	0,907	35
nota_20	0,933	1,000	0,966	28
nota_50	0,934	0,983	0,958	58
nota_100	1,000	0,952	0,976	42
vazio	0,968	0,857	0,909	35
Média macro	0,948	0,944	0,944	278

A acurácia global é de 94,6% (263 de 278), com F1 macro de 0,944 e F1 ponderado de 0,946. A leitura por classe é mais informativa que o número global.

A confusão dominante é *nota_5* prevista como *nota_10*, com 5 ocorrências, responsável sozinha por um terço dos 15




Figura 4. Matriz de confusão do classificador nas 278 imagens de validação.

classe	precisão	revocação	F1	n
nota_10	0,850	0,971	0,907	35
nota_100	1,000	0,952	0,976	42
nota_2	0,953	1,000	0,976	41
nota_20	0,933	1,000	0,966	28
nota_5	1,000	0,846	0,917	39
nota_50	0,934	0,983	0,958	58
vazio	0,968	0,857	0,909	35

Figura 5. Precisão, revocação e F1 por classe.

erros e por quase toda a queda de revocação da classe *nota_5* e de precisão da *nota_10*. O pipeline ajuda a explicar a direção do erro: o recorte da nota é redimensionado para 192×192 antes de entrar na rede, o que destrói a informação de tamanho físico da cédula. Restam cor e padrão gráfico como pistas, e é justamente aí que a distinção fica mais sensível a variação de exposição e a desgaste da nota.

Não houve nenhuma confusão entre as notas de 50 e 100 reais, em nenhuma das duas direções. Esse é o par que a entrevistada relatou confundir, e é a única confusão que o projeto listou como crítica desde a modelagem funcional. O classificador acerta *nota_100* com precisão 1,000 e *nota_50* com revocação 0,983.

Cinco falsos positivos de bancada vazia puxam a revocação de *vazio* para 0,857. Eles são o efeito esperado da localiza-

ção clássica: qualquer resíduo claro sobre o fundo preto vira um contorno que é enviado à rede. Na operação real esses casos são filtrados pelo limiar de 0,8, e a tarefa de objeto claro que não é cédula confirmou o filtro funcionando com os voluntários.

As confusões entre denominações somam 9 casos em 278, ou 3,2%. Como a matriz é calculada por *argmax*, ela mede a capacidade bruta do classificador, e não o comportamento do sistema entregue.

Vale a ressalva metodológica: o *split* de validação é aleatório sobre o mesmo conjunto de dados, capturado nas mesmas sessões, com forte correlação entre imagens vizinhas. Esses 94,6% superestimam o desempenho em condições novas e não substituem um conjunto de teste capturado à parte.

B. Métricas objetivas dos testes com voluntários

O resumo das métricas objetivas está na Tabela VII, e a distribuição por voluntário nas Figs. 6 e 7.

Tabela VII
MÉTRICAS OBJETIVAS DOS TESTES COM 8 VOLUNTÁRIOS

Métrica	Valor
Tarefas executadas	42
Acertos	35
Taxa de acerto global	83,3%
Desvio padrão entre voluntários	11,4 p.p.
Latência percebida média	2,81 s (dp 0,16 s)
Faixa de latência entre sessões	2,6 s a 3,1 s
Valores errados anunciados	0

A latência medida é percebida, e não de inferência: o cronômetro roda do instante em que a cédula toca a bancada até o anúncio falado, incluindo o tempo do voluntário acomodar a nota. O desvio padrão de 0,16 s indica um sistema previsível, propriedade que importa mais que velocidade bruta em uma interface sem retorno visual, porque é o que permite ao usuário saber quando desistir e reposicionar a nota. Nenhum voluntário citou lentidão, e três citaram a rapidez espontaneamente.

C. Natureza dos erros no uso real

Das 7 falhas observadas, nenhuma foi uma confusão entre denominações. A Tabela VIII classifica os erros pela causa identificada nas fichas e nas respostas abertas.

Tabela VIII
CAUSAS DAS FALHAS OBSERVADAS NO USO REAL

Causa	Tipo	Efeito para o usuário
Nota parcialmente fora do campo	Omissão	Silêncio; exige reposicionar
Cédula de 200 reais, fora do modelo	Omissão	Silêncio; limitação de escopo conhecida
Duas notas simultâneas na bancada	Omissão	Silêncio; caso não previsto no pipeline

Esse é o resultado central do trabalho. A modelagem funcional registrou, antes de qualquer implementação, que os erros não têm o mesmo peso, e o corte por confiança em 0,8 foi a materialização dessa decisão. O teste com pessoas de fora

confirmou que ela se sustenta: a matriz de confusão observada no uso real é diagonal, com as falhas concentradas na coluna de ausência de resposta.

Cabe a ressalva de que essa afirmação vem de 42 tarefas registradas em ficha, e de que a matriz de confusão da seção anterior mostra que a rede, avaliada por *argmax* e sem o corte por confiança, ainda confunde denominações em 3,2% das imagens de validação. As duas medidas não se contradizem, pois medem coisas diferentes: uma é a capacidade bruta do classificador, a outra é o comportamento do sistema com o limiar aplicado. O que os testes com voluntários mostram é que o limiar cumpriu o papel de converter erro de classificação em silêncio, e não em valor errado falado.

D. Usabilidade percebida

As dez primeiras questões da enquete formam o SUS [3], pontuado somando (resposta – 1) nos itens positivos e (5 – resposta) nos negativos, com o total multiplicado por 2,5 para produzir um valor de 0 a 100. O valor não é porcentagem: a referência da literatura é que 68 corresponde à média dos sistemas avaliados. Os resultados estão nas Figs. 8 e 9.

O SUS médio foi 96,6, com todas as sessões acima de 87 e quatro com pontuação máxima. A questão adicional sobre interatividade recebeu nota 5 de todos os oito voluntários. A leitura honesta é que a escala está saturada: com um sistema de um gesto só e já configurado pela equipe, o SUS tem pouca margem para discriminar qualidade, e o valor confirma a ausência de atrito sem servir como medida fina.

Os itens mais baixos são os informativos. O item sobre inconsistências no sistema recebeu nota 2 exatamente dos dois voluntários que esbarraram em limitações reais, duas notas ao mesmo tempo e nota parcialmente fora do campo, ou seja, o item negativo capturou justamente as falhas que as métricas objetivas apontaram. O item sobre querer usar o sistema com frequência é naturalmente baixo porque nenhum voluntário tem deficiência visual, de modo que a utilidade percebida no dia a dia é menor que a facilidade percebida.

E. Feedback aberto e compreensão do sistema

A Tabela IX agrupa os temas recorrentes das questões abertas.

Tabela IX
TEMAS RECORRENTES NO FEEDBACK ABERTO

Menções	Tema
4	Elogio: velocidade da resposta
3	Elogio: robustez (nota amassada, dobrada, ângulos)
3	Pedido: somar ou contar várias notas de uma vez
2	Elogio: anúncio falado do valor
1 cada	Elogio por rejeitar o que não é cédula; pedidos de cobrir a nota de 200, aceitar nota parcialmente no campo e integrar a outros sistemas; uma dúvida sobre aplicabilidade

Os dois atributos mais elogiados são exatamente os dois que a modelagem funcional colocou como centrais: a velocidade e o anúncio falado. A crítica dominante não é sobre qualidade,




Figura 6. Taxa de acerto por voluntário, com a taxa global de 83% marcada.




Figura 7. Tempo médio até a resposta falada, por voluntário.




Figura 8. Pontuação SUS por voluntário, todas acima de 87 contra a média de referência de 68.




Figura 9. Contribuição média por item do SUS, de 0 (pior) a 4 (melhor).

e sim sobre alcance: três voluntários pediram, de forma independente, a contagem de várias cédulas de uma vez, o que corresponde ao uso real de conferir um maço em vez de uma nota isolada.

Nas questões de compreensão, sete dos oito voluntários descreveram o objetivo do sistema em termos de identificar o valor de cédulas, e duas pessoas inferiram sozinhas a finalidade de acessibilidade, sem terem sido informadas. A interação, portanto, se explicou sem tutorial.

F. Confronto com as metas da modelagem funcional

A Tabela X confronta o que foi prometido na modelagem funcional com o que foi medido.

Tabela X
METAS DA MODELAGEM FUNCIONAL E RESULTADOS MEDIDOS

Meta	Resultado	Situação
Taxa de acerto no uso real	83,3% (35/42)	Atendido
Ausência de valor falado errado	0 ocorrências	Atendido
Latência percebida	2,81 s (dp 0,16 s)	Atendido
Usabilidade sem treinamento	SUS 96,6	Atendido
Interatividade percebida	5,00 de 5	Atendido
Matriz de confusão por denominação	94,6%, F1 macro 0,944	Atendido
Ausência de confusão entre 50 e 100 reais	0 ocorrências	Atendido
Cobertura de denominações	6 de 7	Parcial
Conjunto de teste independente	Avaliação sobre <i>split</i> de validação	Não atendido
Latência de inferência e FPS	Não instrumentados	Não atendido
Múltiplas cédulas simultâneas	Fora do escopo atual	Não atendido

IV. CONCLUSÃO

O trabalho entregou um sistema funcional que percorre o ciclo completo de visão computacional: filtragem espacial e morfologia, segmentação por limiarização, transformações geométricas de recorte e redimensionamento, e classificação por rede convolucional, fechando com avaliação junto a usuários reais.

Três conclusões se sustentam nos dados. A primeira é que a interação se explica sozinha: pessoas que nunca viram o programa colocam a nota na bancada, ouvem o valor em menos de 3 segundos e descrevem corretamente o que o sistema faz, sem tutorial, com SUS de 96,6 e sete de oito descrições corretas do objetivo.

A segunda é que o erro é conservador por construção, e isso se confirmou na prática. O classificador sozinho ainda confunde denominações em 3,2% das imagens de validação, concentradas no par de 5 e 10 reais, mas nas 42 tarefas com voluntários as 7 falhas foram todas de omissão. A escolha, tomada na modelagem funcional muito antes da implementação, de descartar predições abaixo de 80% de confiança é o que converte erro de rede em silêncio. Vale registrar que a confusão entre as notas de 50 e 100 reais, a que motivou o projeto, não ocorre nem mesmo antes do limiar.

A terceira é que restringir o cenário físico simplificou o software. A bancada preta fosca com câmera fixa transformou a localização da cédula em um problema de limiarização, o que permitiu que uma rede de 155.911 parâmetros treinada do zero resolvesse o problema em tempo real em um notebook. Parte da precisão veio da maquete, e não do modelo.

Como trabalhos futuros, em ordem de retorno esperado: a contagem de múltiplas cédulas, que é o pedido mais frequente do feedback e a única falha estrutural observada, e que exige tratar mais de um contorno por quadro sem mudar o modelo de classificação; um conjunto de teste independente, capturado em sessão separada da de treino, junto com a instrumentação de latência de inferência e taxa de quadros; o reforço das classes de 5 e 10 reais no conjunto de dados, com exemplares desgastados e sob iluminações diferentes; um retorno de posicionamento por voz que distinga bancada vazia de nota cortada, resolvendo a ambiguidade do silêncio; a cobertura da cédula de 200 reais com rebalanceamento entre classes; e uma nova rodada de testes com ao menos um participante com deficiência visual, aplicando a enquete em formato digital com a escala rotulada item a item.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA

Em atendimento à Portaria CNPq 2664/2026, declaramos que ferramentas de Inteligência Artificial Generativa foram utilizadas como apoio na organização e redação deste artigo, especificamente na consolidação dos relatórios de etapa produzidos pela equipe em um texto único, na formatação segundo o modelo IEEEtran e na revisão de clareza das seções. A construção da maquete, a captura e rotulação das 1.393 imagens do conjunto de dados, o treino da rede, as entrevistas da fase de empatia e a condução das sessões de teste com os oito voluntários foram realizadas integralmente pelos autores. Nenhum dado experimental, métrica ou resposta de voluntário foi gerado por IA: todos os números apresentados derivam das fichas preenchidas em papel e da avaliação do modelo treinado. A equipe conferiu e validou o conteúdo final e responsabiliza-se integralmente por ele.

REFERÊNCIAS

- [1] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, Jan. 1979.
- [2] G. Bradski and A. Kaehler, *Learning OpenCV: Computer Vision with the OpenCV Library*. Sebastopol, CA: O'Reilly, 2008.
- [3] J. Brooke, "SUS: a quick and dirty usability scale," in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, Eds. London: Taylor and Francis, 1996, pp. 189–194.
- [4] A. Paszke et al., "PyTorch: an imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems* 32, Vancouver, Canada, 2019, pp. 8024–8035.
- [5] Banco Central do Brasil, "Segunda família do Real: características das cédulas," Brasília, Brasil. [Online]. Available: <https://www.bcb.gov.br>
- [6] Equipe Sem Título, "Programa de reconhecimento de valores de cédulas: código, modelo e relatórios," 2026. [Online]. Available: <https://kaykyb.github.io/ufabc-cv>